

Sistema de Analise e Previsao do Sucesso de Dietas

Elementos de Inteligencia Artificial e Ciencia de Dados

Grupo 7

Erick Gonzalo Salas Duque – 55594

Elkin Jahir Figueroa Torres – 55591

Ismail Can Bingöl – 57343

Maio de 2026

Abstract

Este projeto desenvolve um pipeline simples de ciencia de dados para analisar e prever resultados de dietas usando dados de pacientes, dietas, nutricionistas e resultados clinicos. O conjunto de dados original e composto por quatro ficheiros CSV, que sao primeiro integrados num unico conjunto de dados e depois preparados atraves de limpeza de dados, tratamento de valores em falta, tratamento de outliers e normalizacao.

O projeto segue as tarefas exigidas: integracao de dados, pre-processamento, analise exploratoria de dados, identificacao de padroes, modelacao preditiva e discussao dos resultados. O principal alvo de previsao e a alteracao de peso do paciente apos seis meses, representada por `weight_change_kg_6m`. Alem disso, e criado um alvo binario simples para estimar a probabilidade de sucesso da dieta, em que uma dieta e considerada bem-sucedida se o paciente perder pelo menos 5 kg em seis meses.

Os resultados mostram que variaveis comportamentais e fisicas, especialmente a adesao a dieta, o peso inicial, a idade e o IMC, sao relevantes para explicar a alteracao de peso. Para regressao, sao comparados tres modelos: Regressao Linear, Regressor de Arvore de Decisao e Regressor Random Forest. No conjunto de teste final, a Regressao Linear obtem o melhor RMSE, com um Test RMSE de 2.5266 e um Test R^2 de 0.8818, enquanto o Random Forest tambem apresenta bom desempenho, com um Test RMSE de 3.1535 e um Test R^2 de 0.8158. Um Classificador de Arvore de Decisao simples tambem e usado para estimar a probabilidade de sucesso da dieta.

De modo geral, o projeto mostra que modelos de aprendizagem automatica podem ajudar a analisar resultados de dietas e a identificar fatores importantes relacionados com a perda de peso. No entanto, os resultados devem ser interpretados com cuidado, considerando a simplicidade dos modelos, a definicao escolhida de sucesso e as caracteristicas do conjunto de dados disponivel.

1 Integracao de Dados

A primeira tarefa do projeto foi integrar os quatro ficheiros CSV num unico conjunto de dados unificado. Esta etapa foi implementada no script `src/data_integration.py`, principalmente atraves da funcao `integrate_data()`. As fontes de dados originais foram:

- `patients.csv`
- `diets.csv`
- `nutritionists.csv`
- `outcomes.csv`

O ficheiro `outcomes.csv` foi usado como tabela central porque contem os resultados clinicos dos programas de dieta. Os restantes conjuntos de dados foram unidos a esta tabela usando os seus identificadores correspondentes. Primeiro, `outcomes.csv` foi unido a `patients.csv` usando `patient_id`. Em seguida, o conjunto de dados resultante foi unido a `diets.csv` usando `diet_id`. Por fim, foi unido a `nutritionists.csv` usando `nutritionist_id`.

Todas as operacoes de juncao foram realizadas usando left joins. Esta escolha preserva todos os registos da tabela de resultados, mesmo quando alguma informacao relacionada esta em falta nas tabelas de pacientes, dietas ou nutricionistas. Isto e importante porque os registos de resultados representam as principais observacoes usadas posteriormente para analise e previsao.

Apos a etapa de integracao, o conjunto de dados final continha 2523 linhas e 31 colunas. O resultado foi guardado como `data/merged_data.csv`.

	patient_id	diet_id	nutritionist_id	age	sex	baseline_weight_kg	baseline_bmi	diet_type	mean_adherence_pct	motivation_score	weight_change_kg_6m
0	P0001	D003	N013	42.0	F	78.1	32.2	balanced	85.7	NaN	-20.7
1	P0001	D002	N014	42.0	F	78.1	32.2	balanced	100.0	NaN	-25.6
2	P0001	D009	N015	42.0	F	78.1	32.2	high_protein	88.7	NaN	-24.8
3	P0001	D007	N005	42.0	F	78.1	32.2	high_protein	91.4	NaN	-25.8
4	P0002	D007	N013	28.0	F	88.2	33.4	high_protein	89.0	0.724	-28.1
5	P0002	D003	N009	28.0	F	88.2	33.4	balanced	78.2	0.724	-26.5
6	P0002	D004	N007	28.0	F	88.2	33.4	low_carb	80.8	0.724	-30.9
7	P0003	D007	N015	33.0	F	58.9	22.9	high_protein	82.9	0.630	-18.8
8	P0003	D007	N018	33.0	F	58.9	22.9	high_protein	69.5	0.630	-14.4
9	P0003	D004	N020	33.0	F	58.9	22.9	low_carb	75.9	0.630	-20.3
10	P0003	D005	N017	33.0	F	58.9	22.9	low_carb	81.9	0.630	-23.0
11	P0004	D003	N008	53.0	F	89.4	29.9	balanced	46.3	0.393	-10.6

Figure 1: Exemplos de linhas do conjunto de dados unido apos a integracao de dados.

A Figura 1 mostra uma amostra do conjunto de dados unido apos a etapa de integracao. A tabela contem identificadores de pacientes, dietas e nutricionistas, juntamente com caracteristicas dos pacientes, como idade, sexo, peso inicial e IMC, tipo de dieta, percentagem de adesao, pontuacao de motivacao e a variavel alvo `weight_change_kg_6m`.

Esta etapa de integracao foi necessaria porque as fases seguintes do projeto exigem informacao das quatro fontes ao mesmo tempo. Por exemplo, prever a alteracao de peso requer que a informacao do paciente, da dieta, do nutricionista e do resultado final esteja disponivel numa unica tabela unificada.

2 Limpeza e Pre-processamento de Dados

A segunda tarefa do projeto foi limpar e pre-processar o conjunto de dados unido. Esta etapa foi implementada no script `src/preprocessing.py`, principalmente atraves da funcao `clean_data()`. A funcao recebe o conjunto de dados integrado, `data/merged_data.csv`, e prepara-o para as etapas seguintes do projeto.

Primeiro, as linhas duplicadas foram removidas do conjunto de dados. Neste projeto, foram encontradas e removidas 3 linhas duplicadas. Isto evita que observacoes repetidas afetem a analise exploratoria e o treino dos modelos de previsao.

Depois disso, foram removidas colunas redundantes e de identificadores. As colunas removidas foram:

- `patient_id`
- `diet_id`
- `nutritionist_id`
- `bmi_redundant`
- `experience_years`

As colunas de identificadores foram uteis durante a etapa de integracao de dados, mas foram removidas antes da modelacao porque nao representam caracteristicas preditivas significativas. A coluna `bmi_redundant` foi removida porque duplicava informacao relacionada com o IMC ja presente no conjunto de dados.

Os valores em falta foram tratados de duas formas diferentes. As linhas com valores em falta na variavel alvo, `weight_change_kg_6m`, foram removidas porque nao podem ser usadas para aprendizagem supervisionada. No total, foram eliminadas 151 linhas com valores em falta no alvo. Para os restantes valores em falta, as colunas numericas foram preenchidas com a mediana, enquanto as colunas categoricas foram preenchidas com a moda.

Os outliers foram tratados limitando os valores numericos a tres desvios-padrao da media. Isto reduz a influencia de valores extremos, mantendo ao mesmo tempo os registos correspondentes no conjunto de dados. A variavel alvo nao foi limitada, de modo que os valores originais de alteracao de peso foram preservados.

Por fim, as caracteristicas numericas foram normalizadas usando `StandardScaler`. A variavel alvo `weight_change_kg_6m` foi excluida da normalizacao porque e o valor a prever. A normalizacao e especialmente importante para metodos que dependem da escala das caracteristicas, como o clustering.

O conjunto de dados final limpo e normalizado foi guardado como `data/cleaned_data.csv`.

Etapa	Acao
Remocao de duplicados	Remocao de linhas repetidas
Remocao de colunas	Remocao de IDs e colunas redundantes
Valores alvo em falta	Remocao de linhas sem <code>weight_change_kg_6m</code>
Valores em falta nas caracteristicas	Preenchimento de valores numericos com a mediana e categoricas com a moda
Tratamento de outliers	Limitacao das caracteristicas numericas a 3 desvios-padrao
Normalizacao	Aplicacao de <code>StandardScaler</code> as caracteristicas numericas

Table 1: Resumo das etapas de pre-processamento.

3 Analise Exploratoria de Dados

A terceira tarefa do projeto foi realizar uma analise exploratoria de dados no conjunto de dados limpo. Esta etapa foi implementada no script `src/eda_analysis.py`, principalmente atraves da funcao `run_eda()`. O objetivo desta etapa foi compreender as principais caracteristicas dos dados, identificar possiveis relacoes entre variaveis e observar como diferentes caracteristicas dos pacientes e das dietas se relacionam com a alteracao final de peso.

Primeiro, foram geradas estatisticas descritivas para as variaveis numericas usando a funcao `describe()` do Pandas. Estas estatisticas foram guardadas em `eda_results/summary_statistics`. Este resultado inclui medidas como media, desvio-padrao, minimo, maximo e quartis, que ajudam a fornecer uma visao geral do conjunto de dados limpo.

Depois disso, foi criada uma matriz de correlacao usando as variaveis numericas. Esta matriz ajuda a identificar relacoes lineares entre variaveis como idade, IMC inicial, percentagem de adesao, pontuacao de motivacao e alteracao de peso apos seis meses.




Figure 2: Matriz de correlacao das variaveis numericas.

A Figura 2 mostra a correlacao entre as caracteristicas numericas do conjunto de dados. Esta analise e util para compreender quais variaveis podem estar mais relacionadas com a variavel alvo `weight_change_kg_6m`. Em geral, variaveis comportamentais como a percentagem de adesao e a motivacao sao importantes a considerar porque descrevem o quao bem o paciente seguiu o programa de dieta.

A analise tambem comparou a alteracao de peso de acordo com variaveis categoricas. Primeiro, a relacao entre o sexo do paciente e a alteracao de peso foi analisada usando um boxplot.




Figure 3: Distribuicao da alteracao de peso por sexo do paciente.

A Figura 3 mostra a distribuicao da alteracao de peso para pacientes do sexo masculino e feminino. Este tipo de visualizacao ajuda a identificar se o resultado final da dieta difere fortemente entre grupos. Neste projeto, o sexo foi considerado uma das possiveis variaveis explicativas, mas nao foi analisado isoladamente porque a perda de peso depende de varios fatores ao mesmo tempo.

Em seguida, foi analisada a relacao entre o tipo de dieta e a alteracao de peso. Isto e importante porque diferentes tipos de dieta podem ter efeitos diferentes nos resultados dos pacientes.




Figure 4: Distribuicao da alteracao de peso por tipo de dieta.

A Figura 4 compara a distribuicao da alteracao de peso entre diferentes tipos de dieta. Isto permite observar se algumas categorias de dieta estao associadas a uma melhor perda media de peso. No entanto, estes resultados devem ser interpretados com cuidado, porque o sucesso da dieta tambem depende das caracteristicas do paciente, da motivacao, da adesao e do perfil do nutricionista.

Por fim, foi criada uma visualizacao de outliers para as variaveis numericas. Isto foi util para inspecionar se algumas variaveis continham valores extremos apos o pre-processamento.




Figure 5: Visualizacao em boxplot das variaveis numericas para inspecao de outliers.

A Figura 5 mostra a distribuicao das variaveis numericas apos o pre-processamento. Como os outliers foram tratados durante a etapa de limpeza usando limitacao a tres desvios-padrao, este grafico ajuda a confirmar que os valores extremos foram reduzidos, mantendo os registos no conjunto de dados.

De modo geral, a analise exploratoria de dados forneceu uma primeira compreensao do conjunto de dados e ajudou a orientar as etapas seguintes do projeto. Os graficos gerados mostraram como variaveis numericas e categoricas se relacionam com a alteracao de peso, e tambem apoiaram as etapas posteriores de identificacao de padroes e modelacao preditiva.

4 Identificacao de Padroes e Clustering

A quarta tarefa do projeto foi identificar padroes nos dados usando aprendizagem nao supervisionada. Esta etapa foi implementada no script `src/clustering.py`, principalmente atraves da funcao `run_clustering()`. O objetivo foi agrupar pacientes com perfis semelhantes e depois comparar a alteracao media de peso de cada grupo.

Para esta tarefa, foi usado o algoritmo K-Means. O K-Means e um metodo de clustering simples e amplamente utilizado que separa os dados num numero fixo de grupos. Neste projeto, o numero de clusters foi definido como quatro. Esta escolha mantem a analise simples e permite comparar os grupos facilmente.

O modelo de clustering usou as seguintes características:

- age
- baseline_bmi
- motivation_score
- mean_adherence_pct

Estas variáveis foram selecionadas porque representam características básicas dos pacientes e informação comportamental. Antes de aplicar o K-Means, as características selecionadas foram padronizadas usando `StandardScaler`. Isto foi necessário porque o K-Means é sensível à escala das variáveis.

Após ajustar o modelo, cada paciente foi atribuído a um dos quatro clusters. Os valores médios das características selecionadas e a média de `weight_change_kg_6m` foram então calculados para cada cluster. Os resultados foram guardados em `clustering_results/cluster_averag`. O conjunto de dados completo com os rótulos de cluster atribuídos também foi guardado em `clustering_results/clustered_data.csv`.

Para avaliar o resultado do clustering, foi calculado o *silhouette score*. O valor obtido foi:

Silhouette score: 0.2450

Este valor indica que os clusters estão moderadamente separados. Como o conjunto de dados contém informação de pacientes num estilo semelhante ao mundo real, não se espera uma separação muito clara entre clusters. No entanto, o clustering continua a ser útil para identificar grupos gerais de pacientes e comparar os seus resultados médios.

Cluster	Numero de Pacientes	Alteracao Media de Peso (kg)
0	494	-25.80
1	600	-21.82
2	555	-14.57
3	720	-24.85

Table 2: Alteração média de peso por cluster.

A Tabela 2 mostra que os clusters apresentam alterações médias de peso diferentes. O Cluster 2 teve o resultado médio mais fraco, com uma alteração média de peso de -14.57 kg, enquanto o Cluster 0 teve o resultado médio mais forte, com uma alteração média de peso de -25.80 kg. Isto sugere que o perfil do paciente e as características relacionadas com a adesão podem ser úteis para identificar grupos com diferentes resultados de dieta.




Figure 6: Clusters de pacientes visualizados por idade e IMC inicial.

A Figura 6 mostra os quatro clusters usando idade e IMC inicial como eixos de visualizacao. Embora o modelo tenha usado quatro caracteristicas, este grafico bidimensional ajuda a fornecer uma interpretacao visual simples dos grupos de pacientes.

Alem do clustering, dois padroes especificos mencionados no enunciado do projeto foram testados no script `src/pattern_tests.py`. O primeiro padrao verificou se pacientes com menos de 50 anos perderam mais peso durante os meses mais frios. Neste conjunto de dados, a alteracao media de peso para pacientes mais jovens foi de -23.95 kg nos meses mais frios e de -23.32 kg nos meses mais quentes, pelo que este padrao foi confirmado.

O segundo padrao verificou se nutricionistas mais rigorosos tinham mais pacientes do sexo masculino. A percentagem de pacientes masculinos com nutricionistas rigorosos foi de 48.28%, enquanto a percentagem para outras abordagens de nutricionistas foi de 45.39%. Portanto, este padrao tambem foi confirmado no conjunto de dados.

De modo geral, esta etapa mostrou que a aprendizagem nao supervisionada pode ajudar a identificar grupos de pacientes com diferentes resultados medios de dieta. Os testes adicionais de padroes tambem ajudaram a responder a perguntas especificas do enunciado do projeto de forma simples e interpretavel.

5 Modelacao Preditiva

A quinta tarefa do projeto foi aplicar modelos de aprendizagem supervisionada para prever resultados de dietas. Esta etapa foi implementada no script `src/modeling.py`, principalmente atraves da funcao `run_modeling()`. A principal variavel alvo foi `weight_change_kg_6m`, que representa a alteracao de peso do paciente apos seis meses.

Antes de treinar os modelos, as variaveis categoricas foram convertidas em variaveis numericas usando one-hot encoding. A coluna `record_created_at` foi transformada numa caracteristica de mes mais simples, e colunas de identificadores como `program_id` foram removidas porque nao representam informacao preditiva significativa.

O conjunto de dados foi dividido de acordo com a recomendacao do enunciado do projeto:

- 50% para treino
- 30% para validacao
- 10% para teste
- 10% deixado sem uso para reduzir o sobreajuste

A divisao resultante continha 1184 amostras de treino, 711 amostras de validacao e 237 amostras de teste.

Tres modelos de regressao foram treinados e comparados:

- **Regressao Linear:** usada como um modelo de base simples.
- **Regressor de Arvore de Decisao:** usado porque e interpretavel e recomendado no enunciado do projeto.
- **Regressor Random Forest:** usado como modelo de ensemble para melhorar o desempenho preditivo.

Para o Regressor de Arvore de Decisao, foi realizada uma selecao simples de hiperparametros usando o conjunto de validacao. Os valores testados para `max_depth` foram 3, 5 e 7. O melhor resultado de validacao foi obtido com `max_depth = 5`.

Os modelos foram avaliados usando RMSE, MAE e R^2 . O RMSE e o MAE medem o erro de previsao em quilogramas, enquanto o R^2 mede quanto da variancia da variavel alvo e explicado pelo modelo.

Modelo	Test RMSE	Test MAE	Test R^2
Linear Regression	2.5266	1.9414	0.8818
Decision Tree depth=5	8.4780	3.4797	-0.3313
Random Forest	3.1535	2.1243	0.8158

Table 3: Desempenho dos modelos de regressao no conjunto de teste.

A Tabela 3 mostra que a Regressao Linear alcançou o melhor resultado no conjunto de teste, com o menor RMSE e o maior R^2 . O Random Forest tambem teve bom desempenho, mas ligeiramente inferior ao da Regressao Linear nesta experiencia. O Regressor de Arvore de Decisao teve desempenho pior, especialmente no conjunto de teste, o que sugere que a arvore nao generalizou bem para dados nao vistos.

Embora o resultado da Arvore de Decisao tenha sido mais fraco, ela continua a ser util porque fornece uma estrutura de modelo interpretavel. Isto e importante para explicar o processo de previsao a um publico nao tecnico.




Figure 7: Visualizaco simplificada do Regressor de Arvore de Deciso.

A Figura 7 mostra a estrutura simplificada do Regressor de Arvore de Deciso. Esta visualizaco ajuda a compreender quais variaveis so usadas perto do topo da arvore e como o modelo separa pacientes em diferentes grupos de previso.

Para compreender melhor quais variaveis foram importantes para a previso, a importncia das caracteristicas foi extraída do modelo Random Forest.




Figure 8: As 10 caracteristicas mais importantes segundo o modelo Random Forest.

A Figura 8 mostra que variaveis como peso inicial, percentagem media de adeso, taxa de adeso, idade, sexo, altura e IMC inicial estavam entre as caracteristicas mais importantes. Este resultado  consistente com a ideia de que tanto as caracteristicas fsicas como as variaveis comportamentais influenciam a perda de peso.

Alem de prever a quantidade de alteracao de peso, foi criado um modelo de classificacao simples para estimar a probabilidade de sucesso da dieta. Neste projeto, uma dieta foi considerada bem-sucedida se o paciente perdeu pelo menos 5 kg em seis meses:

$$\text{success} = \begin{cases} 1, & \text{se } \text{weight_change_kg_6m} \leq -5 \\ 0, & \text{caso contrario} \end{cases}$$

Um `DecisionTreeClassifier` com `max_depth = 5` foi treinado usando a mesma divisao de treino, validacao e teste. O modelo gera uma probabilidade de sucesso para cada paciente no conjunto de teste.

Modelo	Test Accuracy	Test F1
Decision Tree Classifier	0.9873	0.9936

Table 4: Desempenho do modelo de classificacao de sucesso no conjunto de teste.

A Tabela 4 mostra que o Classificador de Arvore de Decisao simples alcançou valores elevados de accuracy e F1 score. No entanto, este resultado deve ser interpretado com cuidado porque a definicao de sucesso pode criar uma variavel alvo desequilibrada. Portanto, o modelo de classificacao e util como uma demonstracao simples da probabilidade de sucesso, mas os modelos de regressao fornecem informacao mais detalhada sobre a alteracao de peso esperada.

De modo geral, a etapa de modelacao preditiva mostrou que os resultados de dietas podem ser estimados usando caracteristicas relacionadas com pacientes, dietas e comportamento. A Regressao Linear alcançou o melhor desempenho no teste nesta experiencia, enquanto o Random Forest ajudou a identificar as variaveis preditivas mais importantes.

6 Discussao Critica dos Resultados

Os resultados obtidos neste projeto mostram que o conjunto de dados contem informacao util para compreender e prever resultados de dietas. No entanto, os modelos e padroes devem ser interpretados com cuidado porque o projeto usa um pipeline simples e um conjunto limitado de pressupostos.

Na analise exploratoria de dados, variaveis relacionadas com o comportamento e a condicao fisica dos pacientes pareceram ser importantes. Por exemplo, a percentagem de adesao, o peso inicial, a idade e o IMC foram variaveis relevantes nos modelos de previsao posteriores. Isto e razoavel porque a perda de peso e influenciada nao apenas pelo tipo de dieta, mas tambem pela consistencia com que o paciente segue o plano e pela condicao fisica inicial do paciente.

A etapa de clustering ajudou a identificar grupos de pacientes com diferentes resultados medios. O silhouette score foi 0.2450, o que indica que os clusters nao estao perfeitamente separados. Isto significa que os grupos nao devem ser interpretados como tipos de pacientes muito rigorosos ou claramente isolados. Em vez disso, devem ser vistos como grupos aproximados que ajudam a comparar tendencias gerais. Mesmo com esta limitacao, os clusters mostraram diferentes alteracoes medias de peso, sugerindo que a aprendizagem nao supervisionada pode ser util para descobrir perfis gerais de pacientes.

Na modelacao preditiva, a Regressao Linear alcançou o melhor resultado no conjunto de teste, com um Test RMSE de 2.5266 e um Test R^2 de 0.8818. Isto significa que, nesta

experiencia, um modelo linear mais simples generalizou melhor do que os modelos mais complexos. Uma explicacao possivel e que a relacao entre as variaveis selecionadas e a alteracao de peso e relativamente regular neste conjunto de dados. Outra possibilidade e que o conjunto de dados contenha padroes lineares fortes, especialmente em variaveis relacionadas com a adesao e medidas fisicas iniciais.

O Regressor de Arvore de Decisao foi incluido porque e facil de interpretar e recomendado para este tipo de projeto. No entanto, teve mau desempenho no conjunto de teste, com um Test R^2 negativo. Isto sugere que a arvore nao generalizou bem para dados nao vistos. Mesmo tendo sido usada uma pequena pesquisa de validacao para escolher a melhor profundidade da arvore, o modelo pode ainda ter aprendido padroes demasiado especificos dos dados de treino. Por esta razao, a Arvore de Decisao e mais util aqui como modelo explicativo do que como melhor modelo preditivo.

O Regressor Random Forest teve melhor desempenho do que a Arvore de Decisao e tambem forneceu valores uteis de importancia das caracteristicas. Embora nao tenha superado a Regressao Linear no conjunto de teste, ajudou a identificar quais variaveis eram mais relevantes para a previsao. De acordo com os resultados de importancia das caracteristicas, variaveis como peso inicial, percentagem de adesao, taxa de adesao, idade, sexo, altura e IMC inicial tiveram forte influencia nas previsoes. Isto apoia a ideia de que tanto as caracteristicas fisicas como as variaveis comportamentais sao importantes para os resultados de dietas.

O modelo de probabilidade de sucesso foi implementado como uma tarefa simples de classificacao. Uma dieta foi considerada bem-sucedida se o paciente perdeu pelo menos 5 kg em seis meses. O Classificador de Arvore de Decisao alcançou accuracy e F1 score elevados no conjunto de teste. No entanto, este resultado deve ser interpretado com cuidado. Se a maioria dos pacientes no conjunto de dados for classificada como bem-sucedida de acordo com este limiar, entao uma accuracy elevada pode ser mais facil de obter e pode nao representar totalmente a qualidade do modelo. Portanto, este classificador e util como um exemplo simples de probabilidade de sucesso, mas os modelos de regressao oferecem uma visao mais detalhada porque preveem diretamente a quantidade de alteracao de peso.

De modo geral, os resultados do projeto sugerem que a aprendizagem automatica pode apoiar a analise de resultados de dietas, especialmente ao identificar variaveis importantes e estimar a alteracao de peso esperada. No entanto, os modelos nao devem ser usados como ferramentas de decisao medica sem validacao adicional. Num contexto real, variaveis clinicas adicionais, validacao externa e revisao por especialistas seriam necessarias antes de aplicar estas previsoes a decisoes de tratamento de pacientes.

7 Conclusao

Este projeto implementou um pipeline completo e simples de ciencia de dados para analisar e prever resultados de dietas. O trabalho comecou com a integracao de quatro ficheiros CSV contendo informacao sobre pacientes, dietas, nutricionistas e resultados. Apos a integracao, o conjunto de dados foi limpo, os valores em falta foram tratados, os outliers foram tratados e as variaveis numericas foram normalizadas.

A analise exploratoria de dados foi usada para compreender melhor o conjunto de dados e observar relacoes entre variaveis. Os graficos gerados ajudaram a analisar correlacoes, comparar a alteracao de peso por sexo e tipo de dieta, e inspecionar possiveis outliers. Estas analises apoiaram as etapas seguintes de clustering e modelacao preditiva.

Na etapa de identificacao de padroes, o clustering K-Means foi aplicado para agrupar

pacientes com perfis semelhantes. Os clusters mostraram diferentes alteracoes medias de peso, o que sugere que caracteristicas dos pacientes e variaveis comportamentais podem ajudar a identificar grupos com diferentes resultados de dieta. Alem disso, dois padroes especificos do enunciado do projeto foram testados e confirmados no conjunto de dados.

Na etapa de modelacao preditiva, Regressao Linear, Regressor de Arvore de Decisao e Regressor Random Forest foram treinados para prever `weight_change_kg_6m`. O melhor resultado de teste foi obtido pela Regressao Linear, enquanto o Random Forest foi util para identificar as caracteristicas mais importantes. Um Classificador de Arvore de Decisao simples tambem foi adicionado para estimar a probabilidade de sucesso da dieta, em que sucesso foi definido como perder pelo menos 5 kg em seis meses.

De modo geral, o projeto mostra que metodos de inteligencia artificial e ciencia de dados podem ser uteis para estudar resultados de dietas. Os modelos ajudaram a identificar variaveis relevantes como adesao, peso inicial, idade e IMC. No entanto, os resultados devem ser interpretados com cuidado porque os modelos sao simples e a definicao de sucesso se baseia num limiar fixo. Melhorias futuras poderiam incluir testar mais combinacoes de caracteristicas, usar validacao cruzada, analisar o desequilibrio de classes com mais detalhe e validar os modelos com dados externos.