



Elementos de Inteligência Artificial e Ciência de Dados

Trabalho Prático

Descrição

A crescente prevalência de doenças crónicas associadas a hábitos alimentares inadequados, como a obesidade, a diabetes tipo 2 e as doenças cardiovasculares, têm contribuído para o aumento da consciencialização da sociedade para uma nutrição adequada. Neste contexto, o acompanhamento nutricional personalizado assume um papel determinante na promoção de estilos de vida mais saudáveis e na melhoria dos indicadores clínicos dos pacientes. Contudo, a eficácia de uma dieta depende de um conjunto complexo de fatores, como biológicos, comportamentais, e clínicos, o que torna difícil para os profissionais de saúde prever, com antecedência, quais os planos alimentares com maior probabilidade de sucesso para um determinado perfil de paciente.



O presente trabalho propõe uma abordagem de análise de dados aplicada a um conjunto de dados que engloba informação sobre pacientes, planos dietéticos, nutricionistas responsáveis pelo acompanhamento e resultados das dietas. Estes dados serão facultados em 4 ficheiros CSV distintos correspondentes a cada uma das partes referidas. O objetivo principal é explorar e caracterizar os dados disponíveis, identificar padrões associados ao sucesso ou insucesso das dietas prescritas, e utilizar modelos de previsão capazes de estimar a probabilidade de sucesso de uma dieta com base num conjunto de características do paciente, do respetivo plano alimentar e características do nutricionista que o acompanha. Para isto, será necessário realizar as seguintes tarefas:

- **Integração de Dados.** Esta tarefa prevê a integração dos dados provenientes dos diferentes ficheiros disponíveis, nomeadamente, registos de pacientes, planos dietéticos, informação dos nutricionistas e resultados das dietas num único conjunto de dados unificado;
- **Limpeza e Processamento de Dados.** Nesta tarefa deve ser realizada a limpeza e transformação do conjunto de dados, nomeadamente a remoção de características desnecessárias ou redundantes, o tratamento de valores em falta, a correção ou exclusão de registos com *outliers*, e/ou a aplicação de normalização, de forma a garantir a qualidade e consistência de representação dos dados;
- **Análise Exploratória de Dados.** Nesta tarefa deve realizar-se uma análise detalhada do conjunto de dados integrado, com vista ao estudo de correlações entre as características dos pacientes, os planos alimentares prescritos, o perfil dos nutricionistas e os respetivos resultados clínicos. Nesta análise pode-se também destacar as características redundantes e/ou a existência de *outliers* na análise realizada. Esta tarefa permite identificar padrões e relações diretas entre as variáveis, como por exemplo perceber se o sexo do paciente ou o tipo de dieta estão muito correlacionados com o sucesso da mesma, ou aferir se o perfil do nutricionista é muito ou pouco relevante para a perda de peso do paciente;
- **Identificação de Padrões.** Nesta tarefa pretende-se a descoberta de padrões mais complexos existentes nos dados. Para isso, deverão ser usados métodos de aprendizagem não supervisionada, nomeadamente técnicas de *clustering*, com o objetivo de identificar grupos de pacientes com perfis semelhantes ou padrões recorrentes nas dietas prescritas, identificando os fatores mais associados ao sucesso ou insucesso dos planos alimentares. Esta tarefa tem como objetivo identificar padrões como por exemplo:

– Indivíduos com menos de 50 anos ganham ou perdem mais peso ao fazer dietas em meses frios;

Origem de Imagem: iconicbestiary, no Freepik.

- Nutricionistas mais exigentes têm mais pacientes do sexo masculino.
- **Aplicação de Modelos de Previsão.** Esta tarefa dá seguimento à tarefa anterior no que diz respeito à descoberta de padrões a partir dos dados, mas neste caso para realizar a inferência de variáveis objetivo, com particular foco na variável *sucesso da dieta*. Para isto devem ser utilizados modelos de aprendizagem supervisionada, devendo ser considerados algoritmos de diferentes naturezas, de forma a avaliar qual a abordagem mais adequada ao problema em estudo. O processo de desenvolvimento inclui a divisão dos dados em conjuntos de treino, validação e teste, a seleção de características relevantes e a otimização de hiperparâmetros. Esta tarefa permite avaliar se é possível prever com consistência a perda de peso com base no perfil do paciente, nas características do plano alimentar e do nutricionista, aferir quais as características que mais influenciam o sucesso da dieta, ou aferir se se justifica utilizar todas as características para conseguir obter boas previsões do peso perdido. Esta tarefa deve permitir responder a perguntas como:
 - Quanto peso vou perder se fizer dieta Keto?
 - Qual o tipo de nutricionista que permite maximizar a minha perda de peso para as minhas características?
- **Discussão Crítica dos Resultados.** Nesta tarefa o estudante deve não só avaliar os diversos modelos utilizados segundo métricas de desempenho apropriadas, mas também apresentar uma análise comparativa de diferentes modelos, procurando identificar o modelo com melhor capacidade preditiva e maior potencial de aplicação prática num contexto real. Esta comparação deve ser acompanhada de uma discussão que apresenta as razões para a obtenção dos resultados observados, ou seja, o estudante deve discutir e não apenas descrever os resultados, apontando quais os problemas que justificam o fraco desempenho de alguns modelos.

Elementos a Entregar:

No final do projeto, devem ser entregues através do Moodle os seguintes elementos:

- Repositório Git contendo o código Python usado nas diferentes tarefas do projeto. A avaliação desta componente vai levar em conta a contribuição dos vários elementos do grupo para a produção de código assim como a evolução temporal destas contribuições;
- Relatório organizado de acordo com as tarefas do projeto descrevendo as técnicas usadas em cada uma delas, a justificação para o seu uso, e os resultados obtidos. O relatório deve obrigatoriamente fazer referência à função ou *script* usada para implementar os processos descritos no mesmo, não sendo necessário incluir blocos de código;
- Apresentação das decisões e metodologias utilizadas em cada tarefa, dando ênfase às principais conclusões que se podem extrair dos dados processados, dos padrões identificados e do desempenho dos modelos utilizados.

Avaliação:

A classificação final do projeto será obtida através da seguinte fórmula:

$$Nota_{TP} = 0.8R + 0.2A,$$

sendo R o repositório e relatório desenvolvidos, e A a apresentação do trabalho.

O repositório e o relatório serão avaliados de acordo com as técnicas e metodologias usadas em cada uma das tarefas, tendo em conta a sua correta aplicação e complexidade. Cada fase contribui para a classificação final de acordo com as seguintes percentagens:

- Integração de Dados [5%]
- Limpeza e Processamento de Dados [10%]
- Análise Exploratória de Dados [25%]
- Identificação de Padrões [15%]

- Aplicação de Modelos de Previsão [25%]
- Discussão Crítica de Resultados [20%]

A apresentação irá avaliar a capacidade dos alunos sintetizarem as principais conclusões obtidas ao longo do projeto através dos vários tipos de técnicas da área de Ciência de Dados e Inteligência. A apresentação deve ser orientado para um público alvo menos técnico de forma a que decisores de ligados a áreas distintas à Ciência de Dados consigam perceber o conhecimento que foi possível obter a partir dos dados.